

# 第一章 预备知识与随机过程的基本概念

## 1.1 概 率

概率论的一个基本概念是随机试验. 一个试验 (或观察), 若它的结果预先无法确定, 则称之为**随机试验**, 简称为**试验**(experiment). 所有试验的可能结果组成的集合, 称为**样本空间**, 记作  $\Omega$ .  $\Omega$  中的元素则称为**样本点**, 用  $\omega$  表示. 由  $\Omega$  的某些样本点构成的子集合, 常用大写字母  $A, B, C$  等表示, 由  $\Omega$  中的若干子集构成的集合称为**集类**, 用花写字母  $\mathcal{A}, \mathcal{B}, \mathcal{F}$  等表示.

由于并不是在所有的  $\Omega$  的子集上都能方便地定义概率, 一般只限制在满足一定条件的集类上研究概率性质, 为此引入  $\sigma$  域的概念:

**定义 1.1.1** 设  $\mathcal{F}$  为由  $\Omega$  的某些子集构成的非空集类, 若满足:

- (1) 若  $A \in \mathcal{F}$ , 则  $A^C \in \mathcal{F}$ ,  $A^C$  是  $A$  的补集, 即  $A^C = \bar{A} = \Omega - A$ ;
- (2) 若  $A_n \in \mathcal{F}, n \in \mathbb{N}$ , 则  $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$ .

则称  $\mathcal{F}$  为 **$\sigma$  域**( $\sigma$  代数), 称  $(\Omega, \mathcal{F})$  为**可测空间**.

容易验证, 若  $\mathcal{F}$  为  $\sigma$  域, 则  $\mathcal{F}$  对可列次交、并、差等运算封闭, 即  $\mathcal{F}$  中的任何元素经可列次运算后仍属于  $\mathcal{F}$ . 例: 集类  $\mathcal{F}_0 = \{\emptyset, \Omega\}$ ,  $\mathcal{F}_1 = \{\emptyset, A, A^C, \Omega\}$  及  $\mathcal{F}_2 = \{A: \forall A \subset \Omega\}$  均是  $\sigma$  域, 但集类  $\mathcal{A} = \{\emptyset, A, \Omega\}$  不是  $\sigma$  域.

通常最关心的是包含所要研究对象的最小  $\sigma$  域. 设  $\mathcal{A}$  为由  $\Omega$  的某些子集构成的集类. 一切包含  $\mathcal{A}$  的  $\sigma$  域的交, 记为  $\sigma(\mathcal{A})$ , 称  $\sigma(\mathcal{A})$  为由  $\mathcal{A}$  生成的  $\sigma$  域, 或称为包含  $\mathcal{A}$  的最小  $\sigma$  域. 例:  $\mathcal{A} = \{\emptyset, A, \Omega\}$ , 则  $\sigma(\mathcal{A}) = \{\emptyset, A, A^C, \Omega\}$ . 一维博雷尔(Borel) $\sigma$  域: 包含  $\mathbb{R}$  上所

有形如集合  $(-\infty, a]$  的最小  $\sigma$  域称为一维博雷尔  $\sigma$  域, 记为  $\mathcal{B}$ , 即  $\mathcal{B} = \sigma((-\infty, a], \forall a \in \mathbb{R})$ .

**定义 1.1.2** 设  $(\Omega, \mathcal{F})$  为可测空间,  $P$  是一个定义在  $\mathcal{F}$  上的集函数, 若满足:

- (1)  $P(A) \geq 0, \forall A \in \mathcal{F}$ ; (非负性)
- (2)  $P(\Omega) = 1$ ; (规一性)
- (3) 若  $A_i \in \mathcal{F}, i = 1, 2, \dots$ , 且  $A_i A_j = \emptyset, \forall i \neq j$ , 有

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i). \quad (\text{可列可加性})$$

则称  $P$  为可测空间  $(\Omega, \mathcal{F})$  上的一个**概率测度**(probability measure), 简称**概率**(probability). 称  $(\Omega, \mathcal{F}, P)$  为**概率空间**(probability space), 称  $\mathcal{F}$  为事件域. 若  $A \in \mathcal{F}$ , 则称  $A$  为**随机事件**(random event), 简称为**事件**, 称  $P(A)$  为事件  $A$  的概率.

事件的概率刻画了事件出现可能性的大小. 概率的基本性质如下:

- (1)  $P(\emptyset) = 0, P(A^C) = 1 - P(A)$ .
- (2) 若  $A_1, A_2, \dots, A_n$  互不相容, 则

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i). \quad (\text{有限可加性})$$

- (3) 对任意两个事件  $A$  及  $B$ , 有

$$\begin{aligned} P(A \cup B) &= P(A) + P(B) - P(AB), \\ P(A - B) &= P(A) - P(AB). \end{aligned}$$

- (4) 若  $A \subset B$ , 则  $P(A) \leq P(B)$ .

(5) (若尔当 (Jordan) 公式) 对任意  $A_1, A_2, \dots, A_n$  有

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i A_j) + \sum_{1 \leq i < j < k \leq n} P(A_i A_j A_k) - \dots + (-1)^{n+1} P(A_1 A_2 \cdots A_n).$$

$$P\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n P(A_i).$$

**例 1** (1)  $[0, 1]$  上的博雷尔概率空间. 设  $\Omega = [0, 1]$ ,  $\mathcal{F} = \mathcal{B}[0, 1]$ , 即  $\mathcal{B}[0, 1]$  是  $\mathcal{B}$  局限在  $[0, 1]$  上的博雷尔  $\sigma$ -域. 称  $(\Omega, \mathcal{F}) = ([0, 1], \mathcal{B}[0, 1])$  为  $[0, 1]$  上的博雷尔可测空间. 设在可测空间  $([0, 1], \mathcal{B}[0, 1])$  上定义一概率测度  $P$ , 它满足: 当  $\forall A = [a, b] \in \mathcal{B}[0, 1]$  时,  $P(A) = b - a$ , 称  $(\Omega, \mathcal{F}, P) = ([0, 1], \mathcal{B}[0, 1], P)$  为  $[0, 1]$  上的博雷尔概率空间, 称  $P$  为  $[0, 1]$  上的博雷尔概率测度.

(2) 令  $B = [0, 1]$  上有理点全体,  $\bar{B} = [0, 1]$  上无理点全体.

① 试证:  $B \in \mathcal{F}, \bar{B} \in \mathcal{F}$ ;

② 用概率的定义与性质, 求证  $P(B) = 0, P(\bar{B}) = 1$ .

**证明**  $\forall a \in [0, 1]$ , 单点集  $\{a\} = \bigcap_{n=1}^{\infty} \left[a, a + \frac{1}{n}\right] \in \mathcal{B}[0, 1] = \mathcal{F}$ , 而

$B = \bigcup_n \left\{ \frac{m}{n} : 1 \leq m \leq n, n, m = \{1, 2, \dots\} \right\}$  是可列单点集的并, 故  $B \in \mathcal{F}$ . 且  $\bar{B} = [0, 1] - B \in \mathcal{F}$ . 又  $\forall a \in [0, 1], P(\{a\}) = 0$ , 由完全可加性知  $P(B) = 0$ , 而  $\bar{B} = [0, 1] - B$ , 故  $P(\bar{B}) = 1 - 0 = 1$ .  $\square$

概率的一个重要性质是它具有连续性. 为此先引入事件列的极限.

一事件列  $\{A_n, n \geq 1\}$  称为**单调增序列**, 若  $A_n \subset A_{n+1}, n \geq 1$ ; 称为**单调减序列**, 若  $A_n \supset A_{n+1}, n \geq 1$ . 如果  $\{A_n, n \geq 1\}$  是单调增序列, 定义  $\lim_{n \rightarrow \infty} A_n = \bigcup_{i=1}^{\infty} A_i$ . 如果  $\{A_n, n \geq 1\}$  是单调减序列, 定义

$$\lim_{n \rightarrow \infty} A_n = \bigcap_{i=1}^{\infty} A_i.$$

连续性定理如下.

**命题 1.1.1** 若  $\{A_n, n \geq 1\}$  是单调增序列 (或减序列), 则

$$\lim_{n \rightarrow \infty} P(A_n) = P\left(\lim_{n \rightarrow \infty} A_n\right).$$

**证明** 先设  $\{A_n, n \geq 1\}$  为单调增序列, 令

$$B_1 = A_1, \quad B_n = A_n \left( \bigcup_{i=1}^{n-1} A_i \right)^C = A_n A_{n-1}^C, \quad n > 1.$$

容易验证  $\{B_n, n \geq 1\}$  互不相容. 且有  $\bigcup_{i=1}^n A_i = \bigcup_{i=1}^n B_i, n \geq 1$  及

$$\bigcup_{i=1}^{\infty} A_i = \bigcup_{i=1}^{\infty} B_i, \text{ 故}$$

$$P\left(\lim_{n \rightarrow \infty} A_n\right) = P\left(\bigcup_{i=1}^{\infty} A_i\right) = P\left(\bigcup_{i=1}^{\infty} B_i\right) = \sum_{i=1}^{\infty} P(B_i) \quad (\text{可列可加性})$$

$$= \lim_{n \rightarrow \infty} \sum_{i=1}^n P(B_i) = \lim_{n \rightarrow \infty} P\left(\bigcup_{i=1}^n B_i\right)$$

$$= \lim_{n \rightarrow \infty} P\left(\bigcup_{i=1}^n A_i\right) = \lim_{n \rightarrow \infty} P(A_n). \quad \left(A_n = \bigcup_{i=1}^n A_i\right)$$

若  $\{A_n, n \geq 1\}$  为单调减序列, 则  $\{A_n^C, n \geq 1\}$  为单调增序列, 于是

$$P\left(\bigcup_{n=1}^{\infty} A_n^C\right) = \lim_{n \rightarrow \infty} P(A_n^C),$$

由

$$\bigcup_{n=1}^{\infty} A_n^C = \left(\bigcap_{n=1}^{\infty} A_n\right)^C,$$

有

$$1 - P\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n \rightarrow \infty} (1 - P(A_n)),$$

即

$$P\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n \rightarrow \infty} P(A_n). \quad \square$$

下面是著名的 Borel-Cantelli 引理.

**命题 1.1.2** 设  $\{A_n, n \geq 1\}$  是一事件序列, 若  $\sum_{i=1}^{\infty} P(A_i) < \infty$ ,

则

$$P\left(\limsup_{i \rightarrow \infty} A_i\right) = 0,$$

其中  $\limsup_{i \rightarrow \infty} A_i \triangleq \bigcap_{n=1}^{\infty} \bigcup_{i=n}^{\infty} A_i$ .

**证明** 易知  $\bigcup_{i=n}^{\infty} A_i$  是关于  $n$  的单调减序列, 故由命题 1.1.1 有

$$\begin{aligned} 0 &\leq P\left(\bigcap_{n=1}^{\infty} \bigcup_{i=n}^{\infty} A_i\right) = P\left(\lim_{n \rightarrow \infty} \bigcup_{i=n}^{\infty} A_i\right) \\ &= \lim_{n \rightarrow \infty} P\left(\bigcup_{i=n}^{\infty} A_i\right) \leq \lim_{n \rightarrow \infty} \sum_{i=n}^{\infty} P(A_i) = 0. \end{aligned} \quad \square$$

下面讨论事件间的一种重要关系, 即事件的独立性问题.

两个事件  $A, B \in \mathcal{F}$ , 若满足  $P(AB) = P(A)P(B)$ , 称  $A$  与  $B$  相互独立. 容易证明下列命题等价: ①  $A$  与  $B$  独立; ②  $A$  与  $B^C$  独立; ③  $P(A|B) = P(A)$ ; ④  $P(A|B^C) = P(A)$ .

三个事件  $A, B, C \in \mathcal{F}$ , 若满足

$$P(AB) = P(A)P(B), \quad P(AC) = P(A)P(C), \quad P(BC) = P(B)P(C)$$

及

$$P(ABC) = P(A)P(B)P(C),$$

称  $A, B, C$  相互独立. 请读者证明: 若  $A, B, C$  独立, 则  $A \cup B$  与  $C$ ,  $AB$  与  $C$ ,  $A - B$  与  $C$  相互独立.

$n$  个事件  $A_1, A_2, \dots, A_n \in \mathcal{F}$ , 若对其中任意  $k (2 \leq k \leq n)$  个事件

$$A_{i_1}, A_{i_2}, \dots, A_{i_k} \text{ (其中 } 1 \leq i_1 \leq i_2 \leq \dots \leq i_k \leq n),$$

有  $P(A_{i_1}A_{i_2}\cdots A_{i_k}) = P(A_{i_1})P(A_{i_2})\cdots P(A_{i_k})$ , 称  $A_1, A_2, \dots, A_n$  相互独立.

类似可证明: 若  $A_1, A_2, \dots, A_n$  相互独立, 取  $1 \leq m < n$ , 记  $\mathcal{F}_1 = \sigma(A_k, 1 \leq k \leq m), \mathcal{F}_2 = \sigma(A_k, m+1 \leq k \leq n)$ . 任取  $B_1 \in \mathcal{F}_1, B_2 \in \mathcal{F}_2$ , 则  $B_1$  与  $B_2$  独立.

称事件序列  $\{A_n, n \geq 1\}$  相互独立, 若任取其中有限个均相互独立.

**命题 1.1.3** 若  $\{A_n, n \geq 1\}$  是相互独立的事件序列, 且  $\sum_{n=1}^{\infty} P(A_n) =$

$\infty$ , 则有

$$P\left(\bigcap_{n=1}^{\infty} \bigcup_{i=n}^{\infty} A_i\right) = 1.$$

**证明**

$$P\left(\bigcap_{n=1}^{\infty} \bigcup_{i=n}^{\infty} A_i\right) = P\left(\lim_{n \rightarrow \infty} \bigcup_{i=n}^{\infty} A_i\right) = \lim_{n \rightarrow \infty} P\left(\bigcup_{i=n}^{\infty} A_i\right) = \lim_{n \rightarrow \infty} \left[1 - P\left(\bigcap_{i=n}^{\infty} A_i^C\right)\right].$$

但

$$\begin{aligned}
 P\left(\bigcap_{i=n}^{\infty} A_i^C\right) &= \prod_{i=n}^{\infty} P(A_i^C) && \text{(由独立性)} \\
 &= \prod_{i=n}^{\infty} (1 - P(A_i)) \leq \prod_{i=n}^{\infty} e^{-P(A_i)} && \text{(由 } 1 - x \leq e^{-x}, \quad x \geq 0 \text{)} \\
 &= \exp\left(-\sum_{i=n}^{\infty} P(A_i)\right) = 0. && \left(\text{因为 } \sum_{i=n}^{\infty} P(A_i) = \infty \text{ 对所有 } n\right)
 \end{aligned}$$

因此命题得证. □

## 1.2 随机变量、分布函数及数字特征

### 1. 随机变量与分布函数

考虑一样本空间  $\Omega$ , 记  $\mathbb{R}$  为实数全体之集. 随机变量定义为:

**定义 1.2.1** 设  $(\Omega, \mathcal{F}, P)$  是一概率空间,  $X(\omega)$  是定义在  $\Omega$  上的单值实函数, 如果对  $\forall a \in \mathbb{R}$ , 有  $\{\omega: X(\omega) \leq a\} \in \mathcal{F}$ , 则称  $X(\omega)$  为**随机变量**(random variable).

这里几点说明:

(1)  $\{\omega: X(\omega) \leq a\}$  是指所有满足  $X(\omega) \leq a$  的样本点  $\omega$  的集合, 定义要求  $\{\omega: X(\omega) \leq a\}$  是  $(\Omega, \mathcal{F}, P)$  的一个事件, 因而可定义它的概率.

(2) 定义中  $\omega$  为自变量, 为了书写方便, 简记  $\{\omega: X(\omega) \leq a\} = \{X \leq a\} = \{X \in (-\infty, a]\}$ . 以下把  $X(\omega)$  记为  $X$ , 一般随机变量符号用大写字母  $X, Y, Z$  等表示.

(3)  $X(\omega)$  满足  $\{\omega: X(\omega) \leq a\} \in \mathcal{F}$ , 则易证  $\forall a, b \in \mathbb{R}, \{X > a\}, \{X < a\}, \{X = a\}, \{a < X \leq b\}, \{a \leq X < b\}, \{a < X < b\}, \{a \leq X \leq b\} \in \mathcal{F}$ .

**例 1** 若  $(\Omega, \mathcal{F})$  中的  $\mathcal{F} = \{\emptyset, A, A^C, \Omega\}$ ,  $A \in \mathcal{F}$  而  $A_1 \notin \mathcal{F}$ , 容

易验证  $A_1$  的示性函数  $I_{A_1}(\omega)$  使  $\{I_{A_1} \leq 1/2\} \notin \mathcal{F}$ , 故  $I_{A_1}(\omega)$  对  $\mathcal{F}$  而言不满足随机变量的定义.

**例 2** 给定  $(\Omega, \mathcal{F})$ , 设  $\{B_k\} (0 \leq k < \infty)$  是  $\Omega$  的一个划分, 即  $B_k B_l = \emptyset (k \neq l)$ ;  $\bigcup_{k=1}^{\infty} B_k = \Omega$  且  $B_k \in \mathcal{F} (0 \leq k < \infty)$ , 定义

$X(\omega) = \sum_{k=1}^{\infty} x_k I_{B_k}(\omega)$ , 则容易验证  $X(\omega)$  是随机变量.

可以证明  $B \in \mathcal{B}, \{\omega, X(\omega) \in B\} \in \mathcal{F}$  等价于  $\forall a \in \mathbb{R}, \{\omega, X(\omega) \leq a\} \in \mathcal{F}$ . 参见 [21, 22]. 简记  $X = X(\omega)$ , 且记  $X^{-1}(B) = \{\omega: X(\omega) \in B\}$ .

设  $X$  为  $(\Omega, \mathcal{F}, P)$  上的随机变量, 对  $\forall x \in \mathbb{R}$ , 定义

$$F(x) = P(X \leq x) = P(X \in (-\infty, x]),$$

称  $F(x)$  为  $X$  的**分布函数**(distribution function).

若随机变量  $X$  的可能取值的全体是一可数集或有限集, 则称  $X$  是**离散型随机变量**.

对随机变量  $X$  的分布函数  $F(x)$ , 若存在一非负函数  $f(x)$ , 对  $\forall x \in \mathbb{R}$ , 有

$$F(x) = \int_{-\infty}^x f(u) \, du,$$

则称  $f(x)$  为随机变量  $X$  的**概率密度函数**(probability density function). 若  $f(x)$  连续, 则

$$\frac{dF(x)}{dx} = f(x),$$

即

$$\lim_{h \rightarrow 0} \frac{P(x < X \leq x + h)}{h} = f(x),$$

或

$$P(x < X \leq x + h) = f(x)h + o(h).$$



以上关系是以后用所谓“微元法”求概率密度函数的依据: 为求随机变量  $X$  的概率密度函数, 先求  $X$  落在一个小区间  $(x, x+h]$  上的概率  $P(x < X \leq x+h)$ , 然后令  $h \rightarrow 0$ , 求其极限

$$\lim_{h \rightarrow 0} \frac{P(x < X \leq x+h)}{h},$$

即得  $f(x)$ .

二维随机变量  $(X, Y)$  的**联合分布函数** (joint distribution function)  $F(x, y)$  定义为

$$F(x, y) = P(X \leq x, Y \leq y).$$

$X$  和  $Y$  的**边缘分布**定义为

$$F_X(x) = P(X \leq x) = \lim_{y \rightarrow +\infty} F(x, y) = F(x, +\infty),$$

$$F_Y(y) = P(Y \leq y) = \lim_{x \rightarrow +\infty} F(x, y) = F(+\infty, y).$$

若存在一非负函数  $f(x, y)$ , 对  $\forall (x, y) \in \mathbb{R}^2$  有

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv,$$

则称  $f(x, y)$  为  $(X, Y)$  的**联合概率密度函数**.

称随机变量  $X$  与  $Y$  **相互独立** (independent), 若对  $\forall (x, y) \in \mathbb{R}^2$ , 有

$$F(x, y) = F_X(x)F_Y(y).$$

$n$  维随机向量  $X_1, X_2, \dots, X_n$  的**联合分布函数**定义为

$$F(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n).$$

若对  $\forall (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$  有  $F(x_1, x_2, \dots, x_n) = F_1(x_1)F_2(x_2) \cdots F_n(x_n)$ , 则称  $X_1, X_2, \dots, X_n$  **相互独立**. 这里  $F_i(x_i) = P(X_i \leq x_i)$ .

可以证明, 若  $X, Y, Z$  相互独立, 则  $X \pm Y$  与  $Z$  独立,  $X \cdot Y$  与  $Z$  独立,  $X/Y (Y \neq 0)$  与  $Z$  独立, 更一般有  $g_1(X, Y)$  与  $g_2(Z)$  独立 (其中  $g_1(X, Y), g_2(Z)$  可以是逐段单调函数或逐段连续函数).

## 2. 黎曼—斯蒂尔切斯积分

为以后表示简便, 这里我们引出黎曼—斯蒂尔切斯 (Riemann-Stieltjes) 积分.

设  $F(x)$  为  $(-\infty, +\infty)$  上的单调不减右连续函数,  $g(x)$  为  $(-\infty, +\infty)$  上的单值实函数,  $\forall a < b$ .

**定义 1.2.2** 任取分点  $a = x_0 < x_1 < x_2 < \cdots < x_{i-1} < x_i < \cdots < x_n = b, \forall u_i \in [x_{i-1}, x_i]$ , 作积分和式

$$\sum_{i=1}^n g(u_i) \Delta F(x_i) = \sum_{i=1}^n g(u_i) [F(x_i) - F(x_{i-1})].$$

令  $\lambda = \max_{1 \leq i \leq n} \Delta x_i = \max_{1 \leq i \leq n} (x_i - x_{i-1})$ , 若极限

$$J(a, b) = \lim_{\lambda \rightarrow 0} \sum_{i=1}^n g(u_i) \Delta F(x_i)$$

存在, 则记

$$J(a, b) = \int_a^b g(x) dF(x) \quad \left( \text{或} \int_a^b g(x) F(dx) \right),$$

称极限  $J(a, b)$  为  $g(x)$  关于  $F(x)$  在  $[a, b]$  上的 R-S 积分.

**注** (1)  $\lambda \rightarrow 0$  意味着  $n \rightarrow \infty$ , 且最大子区间的长度趋于 0. (2) 当取  $F(x) = x$  时, R-S 积分化为原来的黎曼 (Riemann) 积分, 所以 R-S 积分是黎曼积分的推广.

当  $a \rightarrow -\infty, b \rightarrow +\infty$  时, 若极限

$$J(-\infty, +\infty) = \lim_{b \rightarrow \infty, a \rightarrow -\infty} \int_a^b g(x) dF(x)$$

存在, 则称

$$J(-\infty, +\infty) = \int_{-\infty}^{+\infty} g(x) dF(x) \quad \left( \text{或} \int_{-\infty}^{+\infty} g(x) F(dx) \right)$$

为  $g(x)$  关于  $F(x)$  在  $(-\infty, +\infty)$  上的 R-S 积分.

R-S 积分的基本性质:

(1) 当  $a < c_1 < \cdots < c_n < b$  时

$$\int_a^b g(x) dF(x) = \sum_{i=0}^n \int_{c_i}^{c_{i+1}} g(x) dF(x) \quad (a = c_0, b = c_{n+1});$$

(2)

$$\int_a^b \sum_{i=1}^n g_i(x) dF(x) = \sum_{i=1}^n \int_a^b g_i(x) dF(x);$$

(3) 若  $g(x) \geq 0$ , 且  $a < b$ , 则

$$\int_a^b g(x) dF(x) \geq 0;$$

(4) 若  $F_1(x), F_2(x)$  为两个分布函数,  $c_1, c_2$  为常数,  $c_1, c_2 > 0$ , 则

$$\int_a^b g(x) d[c_1 F_1(x) + c_2 F_2(x)] = c_1 \int_a^b g(x) dF_1(x) + c_2 \int_a^b g(x) dF_2(x).$$

几个特例:

设  $F(x)$  为  $X$  的分布函数.

(1) 若  $g(x) = 1$ , 则

$$\int_a^b dF(x) = F(b) - F(a) = P(a < X \leq b).$$

(2) 若  $X$  为离散型随机变量, 即  $P(X = c_i) = p_i, i \in \{1, 2, \cdots\}$ ,

则

$$F(x) = \sum_{c_i \leq x} p_i$$

是一跳跃型分布函数, 即  $F(x)$  的变化只在  $c_1, c_2, \dots$  这些点且其跃度为  $p_i$ , 则 R-S 积分

$$\int_{-\infty}^{\infty} g(x) dF(x) = \sum_{n=1}^{\infty} g(c_n)[F(c_n + 0) - F(c_n - 0)] = \sum_{n=1}^{\infty} g(c_n)p_n$$

化成了一个级数.

### 3. 数字特征

(1) 随机变量的数学期望 (expectation or mean)

**定义 1.2.3** 设  $X$  为随机变量,  $F(x)$  为  $X$  的分布函数, 若  $\int_{-\infty}^{+\infty} |x| dF(x)$  存在, 则称

$$EX = \int_{-\infty}^{\infty} x dF(x)$$

为随机变量  $X$  的**数学期望**(或称为  $X$  的均值).

性质 (1) 若  $(c_i, i = 1, 2, \dots, n)$  为常数,  $X_i (i = 1, 2, \dots, n)$  为随机变量, 则

$$E\left(\sum_{i=1}^n c_i X_i\right) = \sum_{i=1}^n c_i EX_i.$$

性质 (2) 设  $g(x)$  为  $x$  的函数,  $F_X(x)$  为  $X$  的分布函数, 若  $E[g(X)]$  存在, 则

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) dF_X(x).$$

当  $X$  为离散型随机变量, 即  $P(X = x_n) = p_n (n \in \mathbb{N})$  时, 则

$$EX = \sum_{n=1}^{\infty} x_n p_n,$$

即  $EX$  是  $X$  所有可能取值的加权平均.

当  $X$  为连续随机变量, 且有概率密度函数  $f(x)$  时, 则

$$EX = \int_{-\infty}^{+\infty} x f(x) dx.$$

## (2) 方差 (variance)

**定义 1.2.4** 令  $DX \triangleq E(X - EX)^2 = EX^2 - (EX)^2$ , 称  $DX$  为随机变量  $X$  的**方差**(有时记  $DX = \text{var } X = \sigma_X^2$ ).

$DX$  刻画了  $X$  取值的集中或分散程度.

## (3) 协方差 (covariance)

**定义 1.2.5** 两个随机变量  $(X, Y)$ , 称

$$\text{cov}(X, Y) \triangleq E[(X - EX)(Y - EY)] = E(XY) - (EX)(EY)$$

为  $(X, Y)$  的**协方差**.

若  $X, Y$  独立, 则  $E(XY) = EX EY$ , 从而得  $\text{cov}(X, Y) = 0$ . 于是, 若  $\text{cov}(X, Y) \neq 0$ , 则  $X, Y$  不独立. 因此  $\text{cov}(X, Y) \neq 0$  刻画了  $X, Y$  取值存在某种统计上的线性相关关系.

## (4) 相关系数 (correlation coefficient)

**定义 1.2.6** 若  $0 < DX = \sigma_X^2 < \infty, 0 < DY = \sigma_Y^2 < \infty$ , 称

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

为  $(X, Y)$  的**相关系数**.

$\rho(X, Y)$  刻画了  $X, Y$  之间线性关系的密切程度, 若  $\rho = 0$ , 称  $X, Y$  不相关.

主要性质:

$$\textcircled{1} \quad D\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i^2 DX_i + 2 \sum_{i < j} a_i a_j \text{cov}(X_i, X_j);$$

② 若  $X_1, X_2, \dots, X_n$  相互独立, 则  $\text{cov}(X_i, X_j) = 0, j \neq i$ , 即  $X_i, X_j$  不相关;

③ 若  $X_1, X_2, \dots, X_n$  两两不相关, 则

$$D\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n DX_i;$$

④ 施瓦茨 (Schwarz) 不等式, 若随机变量  $X, Y$  的二阶矩存在, 则

$$|E(XY)|^2 \leq E(X^2)E(Y^2);$$

特别是

$$|\operatorname{cov}(X, Y)|^2 \leq \sigma_X^2 \sigma_Y^2,$$

$$|\rho(X, Y)| \leq 1.$$

⑤  $\rho = \pm 1$ , 当且仅当

$$P\left(\frac{Y - EY}{\sqrt{DY}} = \pm \frac{X - EX}{\sqrt{DX}}\right) = 1,$$

即  $\rho = \pm 1$ ,  $(X, Y)$  以概率 1 取值在直线  $Y - EY = \pm \sqrt{DY}(X - EX)/\sqrt{DX}$  上.

(5) 矩 (moment)

**定义 1.2.7** 记

$$E(X^k) = \int_{-\infty}^{+\infty} x^k dF_X(x), \quad (k \geq 1),$$

称  $E(X^k)$  为随机变量  $X$  的  $k$  阶矩 ( $k \in \mathbb{N}$ ).

#### 4. 常用随机变量的分布

(1) 离散型随机变量

① 二项分布

设  $0 \leq p < 1, n \geq 1$ , 若  $X$  的分布律为

$$P(X = k) = C_n^k p^k (1 - p)^{n-k}, \quad 0 \leq k \leq n,$$

称  $X$  是参数为  $(n, p)$  的**二项分布**(binomial with parameters  $(n, p)$ ), 简记为  $X \sim B(n, p)$ .

## ② 泊松 (Poisson) 分布

设  $\lambda > 0$ , 若  $X$  的分布律为

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots,$$

称  $X$  是参数为  $\lambda$  的**泊松分布**(Poisson with parameter  $\lambda$ ), 简记为  $X \sim P(\lambda)$ .

## ③ 几何分布

设  $0 < p < 1$ , 若  $X$  的分布律为

$$P(X = k) = (1 - p)^{k-1} p, \quad k = 1, 2, \dots,$$

称  $X$  是参数为  $p$  的**几何分布**(geometric distribution), 简记为  $X \sim G(p)$ .

## (2) 具有概率密度的随机变量

## ① 均匀分布

设  $a < b$ , 若  $X$  的概率密度函数为

$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b, \\ 0, & \text{其他}, \end{cases}$$

称  $X$  是  $(a, b)$  上的**均匀分布**(uniform over  $(a, b)$ ), 简记为  $X \sim U(a, b)$ .

## ② 正态分布

设  $\mu \in \mathbb{R}, \sigma > 0$ , 若  $X$  的概率密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\{-(x - \mu)^2/2\sigma^2\},$$

称  $X$  是参数为  $(\mu, \sigma^2)$  的**正态分布**(normal with parameters  $(\mu, \sigma^2)$ ), 简记为  $X \sim N(\mu, \sigma^2)$ .

## ③ 指数分布

设  $\lambda > 0$ , 若  $X$  的概率密度函数为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

称  $X$  是参数为  $\lambda$  的**指数分布**(exponential with parameter  $\lambda$ ), 简记为  $X \sim E(\lambda)$ .

### 5. 连续型随机变量的事件示性函数的线性组合表示

(1) 设  $X(\omega)$  为非负随机变量  $P(X < \infty) = 1$ , 令

$$X_n(\omega) = \sum_{k=0}^{n2^n-1} \frac{k}{2^n} I_{\{\frac{k}{2^n} \leq X < \frac{k+1}{2^n}\}}(\omega) + n I_{\{X \geq n\}}(\omega),$$

则  $X_n(\omega)$  是随机变量, 满足  $\forall \omega \in \Omega, n \in \mathbb{N}, X_n(\omega) \leq X_{n+1}(\omega)$  (记为  $X_n(\omega) \uparrow$ ), 且当  $0 \leq X(\omega) < n$  时,  $|X_n(\omega) - X(\omega)| < 1/2^n$ ; 当  $X(\omega) = n$  时  $X_n(\omega) = n$ . 故  $\forall \omega \in \Omega, \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ .

(2) 设  $X(\omega)$  为一般的随机变量, 令  $X^+ = X \vee 0 = \max(X, 0)$ ,  $X^- = -(X \wedge 0) = -\min(X, 0)$ , 显然  $X^+, X^- \geq 0$  由上面的结论, 对  $X^+, X^-$  存在  $X_n^+ \uparrow X^+, X_n^- \uparrow X^-$ . 令  $X_n = X_n^+ - X_n^-$ , 则  $X_n \uparrow X$ .

## 1.3 矩母函数、特征函数和拉普拉斯变换

### 1. 矩母函数 (moment generating function)

**定义 1.3.1** 随机变量  $X$  的**矩母函数**定义为

$$\psi(t) \triangleq E(e^{tX}) = \int_{-\infty}^{+\infty} e^{tx} dF_X(x),$$

如果上式右边积分存在.

显然, 如  $X$  的  $k$  阶矩存在, 则

$$E(X^k) = \psi^{(k)}(0).$$



矩母 (生成) 函数由此得名. 可以证明矩母函数与分布函数是一一对应的.

对于取值非负整数的随机变量  $X$ , 即  $P(X = k) = p_k \geq 0 (k \geq 0)$ ,  $\sum_{k=0}^{\infty} p_k = 1$ , 则  $X$  的矩母函数记为

$$g(s) = E(s^X) = \sum_{k=0}^{\infty} p_k s^k, \quad 0 \leq s \leq 1.$$

显然  $p_k = g^{(k)}(0)/k!$ , 且有  $E[X(X-1)(X-2)\cdots(X-k+1)] = g^{(k)}(1)$ . 若  $X_1, X_2$  相互独立, 其矩母函数分别记为  $g_1(s), g_2(s)$ , 则不难证明  $X_1 + X_2$  的矩母函数为

$$g_{X_1+X_2}(s) = g_1(s)g_2(s).$$

对于数列  $\{a_n, n \geq 0\}$ , 如

$$A(s) = \sum_{n=0}^{\infty} a_n s^n, \quad |s| \leq 1,$$

则称  $A(s)$  为  $\{a_n, n \geq 0\}$  的**母函数**.

母函数的几个重要性质:

- (1)  $E(X) = g'(1)$ .
- (2)  $D(X) = g''(1) + g'(1) - [g'(1)]^2$ .
- (3)  $g'(1) = \sum_{k=1}^{\infty} k p_k$ .

## 2. 特征函数 (characteristic function)

**定义 1.3.2** 记

$$\phi(t) \triangleq E\{\exp(itX)\} = \int_{-\infty}^{+\infty} \exp(itx) dF_X(x),$$

其中  $i = \sqrt{-1}$ ,  $-\infty < t < +\infty$ . 称  $\phi(t)$  是随机变量  $X$  的**特征函数**.

$\phi(t)$  的几个重要性质:

(1)  $\phi(0) = 1$ ,  $|\phi(t)| \leq \phi(0)$ ,  $\phi(-t) = \overline{\phi(t)}$ , 且  $\phi(t)$  在  $(-\infty, +\infty)$  上 — 致 连续.

(2)  $\phi(t)$  具有非负定性, 即对任给  $n$  个实数  $t_i$  及复数  $\lambda_i (1 \leq i \leq n)$  有

$$\sum_{j=1}^n \sum_{i=1}^n \phi(t_i - t_j) \lambda_i \overline{\lambda_j} \geq 0.$$

(3) 若  $X$  与  $Y$  相互独立, 则

$$\phi_{X+Y}(t) = \phi_X(t) \phi_Y(t).$$

(4) 随机变量  $X$ , 若  $EX^n$  存在, 则当  $k \leq n$  时

$$\phi^{(k)}(0) = i^k E(X^k).$$

(5) 随机变量的分布函数与特征函数有一一对应的关系, 即给定  $F(x)$  可唯一决定  $\phi(t)$ ; 反之, 给定  $\phi(t)$  可唯一决定  $F(x)$  (唯一性定理).

上述性质的证明详见参考文献 [20].

### 3. 拉普拉斯—斯蒂尔切斯变换

**定义 1.3.3** 设非负随机变量  $X$ , 分布函数  $F_X(x)$ ,  $s = a + bi$ , 这里  $a > 0$ ,  $b$  是实数, 称

$$\widehat{F}_X(s) = \int_0^{+\infty} \exp(-sx) dF_X(x)$$

为  $F_X(x)$  的拉普拉斯—斯蒂尔切斯变换 (Laplace-Stieltjes transform, 简记 L-S 变换), 或称随机变量  $X$  的 L-S 变换.

注  $\hat{F}_X(s)$  与  $F_X(x)$  也有一一对应关系, 且对  $X_1, X_2 \geq 0$  相互独立, 有

$$\hat{F}_{X_1+X_2}(s) = \hat{F}_{X_1}(s)\hat{F}_{X_2}(s).$$

## 1.4 条件数学期望

条件数学期望是随机过程中最基本最重要的概念之一. 为了直观地对此概念有正确的理解. 我们先从离散型随机变量入手, 再讨论连续型随机变量情形, 然后推广到多元随机变量的情形.

### 1. 离散型随机变量的情形

设两随机事件  $A, B$ , 若  $P(B) > 0$ , 称  $P(A|B) = P(AB)/P(B)$  为事件  $B$  发生时, 事件  $A$  的**条件概率**(若  $P(B) = 0$ , 则  $P(A|B)$  没定义或规定为 0). 设  $(X, Y)$  为两个离散型随机变量, 其联合分布律为  $P(X = x_i, Y = y_j) = p_{ij} \geq 0$ ,  $\sum_i \sum_j p_{ij} = 1$ , 若  $P(Y = y_j) = \sum_i p_{ij} \triangleq p_{\cdot j} > 0$ , 称

$$P(X = x_i | Y = y_j) = P(X = x_i, Y = y_j) / P(Y = y_j) = p_{ij} / p_{\cdot j}$$

为给定  $Y = y_j$  时  $X$  的**条件分布律**. 称

$$E(X|Y = y_j) \triangleq \sum_i x_i P(X = x_i | Y = y_j)$$

为给定  $Y = y_j$  时  $X$  的**条件数学期望**.

比较 (无条件) 数学期望  $EX = \sum_i x_i P(X = x_i)$  与条件数学期望  $E(X|Y = y_j)$  的异同.  $EX$  是对所有  $\omega \in \Omega$ ,  $X(\omega)$  取值全体的加权平均; 而  $E(X|Y = y_j)$  是局限在  $\omega \in \{\omega: Y(\omega) = y_j\} \triangleq B_j$  时,  $X(\omega)$  取值局部 ( $\omega \in B_j$ ) 的加权平均. 这是因为: 记  $B_j = \{\omega: Y = y_j\}$ ,  $A_i = \{\omega: X = x_i\}$ , 于是整个样本空间  $\Omega$  按  $Y$  的不同取值分为

$B_1, \dots, B_j, \dots$  等互不相容的事件  $(\Omega = \sum_j B_j)$ . 而  $\Omega$  又按  $X$  不同

取值分为  $A_1, \dots, A_i, \dots$  等互不相容的事件  $(\Omega = \sum_i A_i)$ .

当  $A_i B_j = \emptyset$  时,  $P(X = x_i, Y = y_j) = 0$ ,  $P(X = x_i | Y = y_j) = 0$ , 于是

$$E(X | Y = y_j) = \sum_i x_i P(X = x_i | Y = y_j) = \sum_{i: A_i B_j \neq \emptyset} x_i P(X = x_i | Y = y_j).$$

因此  $E(X | Y = y_j)$  是  $\omega \in B_j$  时  $X(\omega)$  的局部加权平均.

显然,  $E(X | Y = y_1), \dots, E(X | Y = y_j), \dots$ , 依赖于  $Y = y_j$ , 即依赖于  $\omega \in B_j = \{\omega: Y = y_j\}$ , 这样, 从全局样本空间  $\Omega$  及对  $\omega \in \Omega$  可以变化的观点看, 有必要引进一个新的随机变量, 记为  $E(X | Y)$ . 对于这个随机变量  $E(X | Y)$ , 当  $\omega \in B_j$  时 (即  $Y = y_j$  时) 它的取值为  $E(X | Y = y_j)$ , 称随机变量  $E(X | Y)$  为随机变量  $X$  关于随机变量  $Y$  的条件数学期望.

为给出  $E(X | Y)$  的确切定义及表示式, 引进事件的示性函数如下: 记

$$I_{B_j}(\omega) = \begin{cases} 1, & \omega \in B_j = \{\omega: Y(\omega) = y_j\}, \\ 0, & \omega \notin B_j = \{\omega: Y(\omega) = y_j\}. \end{cases}$$

显然  $I_{B_j}(\omega) = 1 \leftrightarrow Y(\omega) = y_j$  发生, 亦记  $I_{B_j}(\omega) = I_{(Y=y_j)}(\omega)$ .

**定义 1.4.1** 记

$$E(X | Y) \triangleq \sum_j I_{(Y=y_j)}(\omega) E(X | Y = y_j), \quad (1.4.1)$$

称  $E(X | Y)$  为  $X$  关于  $Y$  的条件数学期望.

$E(X | Y)$  的定义包含如下的直观意义:

(1) 随机变量  $E(X|Y)$  是随机变量  $Y$  的函数, 当  $\omega \in \{\omega: Y = y_j\}$  时,  $E(X|Y)$  的取值为  $E(X|Y = y_j)$ . 事实上, 它是局部平均  $\{E(X|Y = y_j), j \in \mathbb{N}\}$  的统一表达式.

(2) 当  $E(X|Y = y_j) \neq E(X|Y = y_k) (j \neq k)$  时,  $P[E(X|Y) = E(X|Y = y_j)] = P(Y = y_j)$ ; 否则, 令  $D_j = \{k: E(X|Y = y_k) = E(X|Y = y_j)\}$ , 则

$$P\{E(X|Y) = E(X|Y = y_j)\} = \sum_{k \in D_j} P(Y = y_k).$$

(3) 由于随机变量  $E(X|Y)$  是随机变量  $Y$  的函数, 故它的数学期望应为

$$E(E(X|Y)) = \sum_j E(X|Y = y_j)P(Y = y_j).$$

**例 1** 随机变量  $(X, Y)$  的联合分布律如表 1.1.

表 1.1

$\begin{smallmatrix} X \\ Y \end{smallmatrix}$	1	2	3	$p_{\cdot j}$
1	2/27	4/27	1/27	7/27
2	5/27	7/27	3/27	15/27
3	1/27	2/27	2/27	5/27
$p_{i \cdot}$	8/27	13/27	6/27	

试求  $E(X|Y)$  的分布律,  $EX$  及  $E(E(X|Y))$ .

**解** 为求  $E(X|Y = j)$ , 先求  $P(X = i, Y = j), i, j = 1, 2, 3$ . 当  $Y = 1$  时, 有

$$P(X = 1|Y = 1) = P(X = 1, Y = 1)/P(Y = 1) = \frac{2/27}{7/27} = \frac{2}{7},$$

同理  $P(X=2|Y=1)=4/7, P(X=3|Y=1)=1/7$ . 故

$$E(X|Y=1) = \sum_{i=1}^3 iP(X=i|Y=1) = 1 \times \frac{2}{7} + 2 \times \frac{4}{7} + 3 \times \frac{1}{7} = \frac{13}{7}.$$

类似地有

$$E(X|Y=2) = \sum_{i=1}^3 iP(X=i|Y=2) = 1 \times \frac{5}{15} + 2 \times \frac{7}{15} + 3 \times \frac{3}{15} = \frac{28}{15},$$

$$E(X|Y=3) = \sum_{i=1}^3 iP(X=i|Y=3) = 1 \times \frac{1}{5} + 2 \times \frac{2}{5} + 3 \times \frac{2}{5} = \frac{11}{5}.$$

又  $P\{E(X|Y) = E(X|Y=j)\} = P(Y=j), j=1, 2, 3$ . 故  $E(X|Y)$  的分布律列表如下: 于是

$E(X Y=j)$	13/7	28/15	11/5
$P\{E(X Y) = E(X Y=j)\} = P(Y=j)$	7/27	15/27	5/27

$$E(E(X|Y)) = \frac{13}{7} \times \frac{7}{27} + \frac{28}{15} \times \frac{15}{27} + \frac{11}{5} \times \frac{5}{27} = \frac{52}{27},$$

而

$$EX = \sum_{i=1}^3 iP(X=i) = 1 \times \frac{8}{27} + 2 \times \frac{13}{27} + 3 \times \frac{6}{27} = \frac{52}{27},$$

得

$$EX = E(E(X|Y)) = \frac{52}{27}. \quad \square$$

自然要问, 一般情形下, 是否  $EX = E(E(X|Y))$ ? 它的直观意义又是什么? 试证明:

- (1) 在  $(X, Y)$  为离散随机变量且  $E|X| < \infty$  时  $EX = E(E(X|Y))$ ;  
 (2)  $E(X|X) = X$ .

## 2. 连续随机变量 $(X, Y)$ 的情形

设  $(X, Y)$  的联合概率密度函数 (jointly probability density function) 为  $f(x, y)$ ,  $Y$  的概率密度函数为  $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$ , 设  $f_Y(y) > 0, E|X| < \infty$ , 给定  $Y = y, X$  的条件概率密度函数为

$$f_{X|Y=y}(x|y) = \frac{f(x, y)}{f_Y(y)},$$

条件分布函数为

$$F_{X|Y=y}(x|y) = P(X \leq x | Y = y) = \int_{-\infty}^x \frac{f(u, y)}{f_Y(y)} du,$$

条件数学期望为

$$E(X|Y = y) = \int_{-\infty}^{+\infty} x f_{X|Y=y}(x|y) dx = \int_{-\infty}^{+\infty} x \frac{f(x, y)}{f_Y(y)} dx. \quad (1.4.2)$$

令  $D \in \mathcal{B}$ , 考虑  $Y \in D$  下, 若  $P(Y \in D) > 0$ ,  $X$  的条件分布函数为

$$F(x|D) = P\{X \leq x | Y \in D\} = \frac{P(X \leq x, Y \in D)}{P(Y \in D)} = \frac{\int_{-\infty}^x \left( \int_{y \in D} f(x, y) dy \right) dx}{\int_{y \in D} f_Y(y) dy}.$$

在  $Y \in D$  下,  $X$  的条件概率密度函数为

$$f_{X|D}(x|D) = \frac{\int_{y \in D} f(x, y) dy}{P(Y \in D)}. \quad (1.4.3)$$

于是在  $Y \in D$  下,  $X$  的条件数学期望定义为

$$E(X|Y \in D) \triangleq \int_{-\infty}^{+\infty} x f_{X|D}(x|D) dx = \int_{y \in D} \left( \int_{-\infty}^{+\infty} x f(x, y) dx \right) dy / P(Y \in D).$$

由上式定义, 有

$$\begin{aligned} E(X|Y \in D) &= \int_{y \in D} \left( \int_{-\infty}^{+\infty} x \frac{f(x, y)}{f_Y(y)} dx \right) f_Y(y) dy / P(Y \in D) \\ &= \frac{1}{P(Y \in D)} \int_{y \in D} E(X|Y = y) f_Y(y) dy. \end{aligned}$$

显然, 条件数学期望  $E(X|Y = y)$  是  $y$  的函数. 这样, 从整个样本空间  $\Omega$  及从  $\omega \in \Omega$  可以变化的宏观上看, 可以且有必要定义一个随机变量  $E(X|Y)$ , 使其在  $Y = y$  时,  $E(X|Y)$  的取值为  $E(X|Y = y)$ .

**定义 1.4.2** 设  $(X, Y)$  具有联合概率密度函数  $f(x, y)$ ,  $Y$  的概率密度函数为  $f_Y(y) > 0$ ,  $E|X| < \infty$ , 若随机变量  $E(X|Y)$  满足:

- (1)  $E(X|Y)$  是随机变量  $Y$  的函数, 当  $Y = y$  时, 它的取值为  $E(X|Y = y)$ ;
- (2) 对任意  $D \in \mathcal{B}$ , 有

$$E[E(X|Y)|Y \in D] = E(X|Y \in D). \quad (1.4.4)$$

称随机变量  $E(X|Y)$  为  $X$  关于  $Y$  的条件数学期望.

从 (1), 由于  $E(X|Y)$  是随机变量  $Y$  的函数, 故它的数学期望应为

$$E[E(X|Y)] = \int_{-\infty}^{+\infty} E(X|Y = y) f_Y(y) dy.$$

而从 (2), 当取  $D = \mathbb{R} = (-\infty, +\infty)$  时

$$\begin{aligned} EX &= E\{X|Y \in (-\infty, +\infty)\} = E\{E(X|Y)|Y \in (-\infty, \infty)\} = E[E(X|Y)] \\ &= \int_{-\infty}^{+\infty} E(X|Y = y) f_Y(y) dy. \end{aligned}$$

**例 2**  $(X, Y)$  是二维正态分布, 即  $(X, Y) \sim N(\mu_1, \mu_2, \rho, \sigma_1^2, \sigma_2^2)$ ,



则联合概率密度函数为

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2(1-\rho^2)^{\frac{1}{2}}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\},$$

则

$$\begin{aligned} f_{Y|X=x}(y|x) &= \frac{f(x, y)}{f_X(x)} \\ &= \frac{1}{\sqrt{2\pi}\sigma_2(1-\rho^2)^{\frac{1}{2}}} \exp\left\{-\frac{1}{2\sigma_2^2(1-\rho^2)}\left[y - \mu_2 - \rho\frac{\sigma_2}{\sigma_1}(x - \mu_1)\right]^2\right\} \\ &\sim N\left(\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1-\rho^2)\right). \end{aligned}$$

故

$$\begin{aligned} E(Y|X=x) &= \mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x - \mu_1); \\ E(Y|X) &= \mu_2 + \rho\frac{\sigma_2}{\sigma_1}(X - \mu_1). \end{aligned} \quad (1.4.5)$$

此时  $E(Y|X)$  是  $X$  的线性函数, 这是正态分布的重要性质.  $\square$

### 3. 一般随机变量的情形

设  $(X, Y)$  为一般随机变量, 其联合分布函数为  $P(X \leq x, Y \leq y)$ . 以下假设  $E|X| < \infty$ , 分两种情况讨论.

**定义 1.4.3** 设  $D \in \mathcal{B}, P(Y \in D) > 0, \forall x \in \mathbb{R}$ , 称  $P(X \leq x|Y \in D) = P(X \leq x, Y \in D)/P(Y \in D)$  为  $X$  关于事件  $\{Y \in D\}$  的条件分布函数. 容易证明, 若  $X$  与  $Y$  独立, 则对  $\forall x \in \mathbb{R}, \forall D \in \mathcal{B}, P(X \leq x|Y \in D) = P(X \leq x)$ . 称  $E(X|Y \in D) = \int_{\mathbb{R}} x dP(X \leq x|Y \in D)$  为  $X$  关于  $\{Y \in D\}$  的条件数学期望.

在许多问题中常常需要考虑  $D$  为单点集  $\{y\}$  的情形. 若  $P(Y = y) > 0$ , 这时定义条件分布同上. 问题是当  $P(Y = y) = 0$  时, 如何定义  $P(X \leq x|Y = y)$ .

**定义 1.4.4** 设  $(x, y) \in \mathbb{R}^2$ , 对充分小的  $h > 0$ , 有  $P(y < Y \leq y + h) > 0$ . 若  $P(X \leq x | Y = y) \triangleq \lim_{h \rightarrow 0} P(X \leq x | y < Y \leq y + h)$  存在, 则称  $P(X \leq x | Y = y)$  为  $X$  关于  $\{Y = y\}$  的条件分布函数, 称  $E(X | Y = y) = \int_{\mathbb{R}} x dP(X \leq x | Y = y)$  为  $X$  关于  $\{Y = y\}$  的条件数学期望.

若随机变量  $E(X | Y)$  满足:

(1)  $E(X | Y)$  是随机变量  $Y$  的函数, 当  $Y = y$  时, 它的取值为  $E(X | Y = y)$ .

(2) 对于  $\forall D \in \mathcal{B}$ ,  $E\{E(X | Y) | Y \in D\} = E(X | Y \in D)$ .

称随机变量  $E(X | Y)$  为  $X$  关于  $Y$  的条件数学期望.

从该定义中的 (1) 知  $E(X | Y)$  是随机变量  $Y$  的函数, 则它的数学期望为

$$E[E(X | Y)] = \int_{\mathbb{R}} E(X | Y = y) dP(Y \leq y).$$

但是从 (2) 知, 当取  $D = \mathbb{R} = (-\infty, +\infty)$  时, 有

$$EX = E(X | Y \in (-\infty, +\infty)) = E\{E(X | Y) | Y \in (-\infty, +\infty)\} = E\{E(X | Y)\},$$

故有  $EX = E\{E(X | Y)\}$ , 即

$$EX = \int_{\mathbb{R}} E(X | Y = y) dP(Y \leq y). \quad (1.4.6)$$

上式可看作是数学期望形式的全概率公式.

#### 4. 条件概率与条件分布函数

设随机变量  $(X, Y)$  及任一随机事件  $B \in \mathcal{F}$ , 记

$$I_B(\omega) = \begin{cases} 1, & \omega \in B, \\ 0, & \omega \notin B, \end{cases}$$

即  $I_B$  是  $B$  的示性函数. 显然

$$P(B) = E(I_B(\omega)).$$

称

$$E(I_B(\omega)|Y) \triangleq P(B|Y)$$

为事件  $B$  关于随机变量  $Y$  的条件概率. 此时  $P(B|Y)$  是随机变量且是  $Y$  的函数, 对于  $\forall x \in \mathbb{R}$ , 取  $B = (\omega: X \leq x)$ , 称

$$F(x|Y) \triangleq P(X \leq x|Y) = E(I_{(X \leq x)}|Y) \quad (1.4.7)$$

为  $X$  关于  $Y$  的条件分布函数.

于是有关条件概率, 条件分布函数均可用条件数学期望的概念及性质来处理.

### 5. 条件数学期望的基本性质

两个随机变量  $Z_1, Z_2$ , 如果  $P(Z_1 = Z_2) = 1$ , 称  $Z_1, Z_2$  几乎处处 (或称几乎必然) 相等, 记作  $Z_1 = Z_2$  a.s..

设  $X, Y, X_i (1 \leq i \leq n)$  为随机变量,  $g(x), h(y)$  为一般函数, 且  $E|X|, E|X_i| < \infty (1 \leq i \leq n), E|g(X)h(Y)| < \infty, E|g(X)| < \infty$ . 则有

(1)

$$E(E(X|Y)) = EX. \quad (1.4.8)$$

(2)

$$E\left(\sum_{i=1}^n \alpha_i X_i | Y\right) = \sum_{i=1}^n \alpha_i E(X_i | Y) \quad \text{a.s.}, \quad (1.4.9)$$

其中  $\alpha_i (1 \leq i \leq n)$  为常数.

(3)

$$E[(g(X)h(Y)|Y] = h(Y)E(g(X)|Y) \quad \text{a.s.}, \quad (1.4.10)$$

特别地

$$\begin{aligned} E(X|X) &= X \quad \text{a.s.}, \\ E[g(X)h(Y)] &= E[h(Y)E(g(X)|Y)]. \end{aligned} \quad (1.4.11)$$

(4) 如  $X, Y$  相互独立, 则

$$E(X|Y) = EX.$$

下面仅证 (1.4.11) 式, 其他留作练习.

设  $(X, Y) \sim f(x, y)$ , 则

$$\begin{aligned} E(g(X)h(Y)) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x)h(y)f(x, y) \, dx \, dy \\ &= \int_{-\infty}^{+\infty} \left[ \int_{-\infty}^{+\infty} g(x) \frac{f(x, y)}{f_Y(y)} \, dx \right] h(y) f_Y(y) \, dy \\ &= \int_{-\infty}^{+\infty} E(g(X)|Y = y) h(y) f_Y(y) \, dy \\ &= E[h(Y)E(g(X)|Y)]. \end{aligned}$$

由上面倒数第二式, 有

$$E(g(X)h(Y)) = \int_{-\infty}^{+\infty} E(g(X)|Y = y) h(y) f_Y(y) \, dy. \quad (1.4.12)$$

特别地, 取  $g(X) = I_A(\omega)$ ,  $h(y) \equiv 1$  时, 得

$$P(A) = \int_{-\infty}^{+\infty} P(A|Y = y) f_Y(y) \, dy.$$

(1.4.12) 式是全概率公式的推广.

## 6. 对多元随机变量的条件数学期望

### (1) 离散型随机变量

设三个随机变量  $(X, Y, Z)$ , 其中  $(Y, Z)$  为离散随机变量, 称随机变

$E(X|Y, Z)$  是  $X$  关于  $Y, Z$  的条件数学期望, 若它满足:

①  $E(X|Y, Z)$  是  $(Y, Z)$  的二元函数, 当  $Y = y_j; Z = z_k$  时,  $E(X|Y, Z)$  的取值为  $E(X|Y = y_j; Z = z_k)$ ;

② 对任意  $D_j \in \mathbb{R}^1, D_k \in \mathbb{R}^1$ , 有

$$E[E(X|Y, Z)|Y \in D_j, Z \in D_k] = E(X|Y \in D_j, Z \in D_k),$$

用示性函数表示, 即

$$E(X|Y, Z) \triangleq \sum_j \sum_k I_{(Y=y_j, Z=z_k)}(\omega) E(X|Y = y_j, Z = z_k).$$

当  $E|X| < \infty$  时, 请读者证明

$$E[E(X|Y, Z)|Y] = E(X|Y) = E[E(X|Y)|Y, Z]. \quad (1.4.13)$$

### (2) 连续型随机变量

如  $(X, Y, Z)$  为连续型随机变量, 联合概率密度函数为  $f(x, y, z)$ ;  $(Y, Z)$  的联合概率密度函数为  $f_{Y,Z}(y, z)$ ;  $X$  关于  $Y = y, Z = z$  的条件概率密度函数为

$$f_{X|(Y,Z)=(y,z)}(x|y, z) = f(x, y, z)/f_{Y,Z}(y, z),$$

设  $E|X| < \infty, f_{Y,Z}(y, z) > 0$ , 若随机变量  $E(X|Y, Z)$  满足:

①  $E(X|Y, Z)$  是  $Y, Z$  的函数, 当  $Y = y, Z = z$  时, 它们取值为

$$E(X|Y = y, Z = z).$$

② 对任意  $D_1 \in \mathbb{R}^1, D_2 \in \mathbb{R}^1$ , 有

$$E\{(E(X|Y, Z)|Y \in D_1, Z \in D_2)\} = E(X|Y \in D_1, Z \in D_2).$$

称  $E(X|Y, Z)$  为  $X$  关于  $(Y, Z)$  的条件数学期望.

(3)  $n$  元随机变量

对离散随机变量  $\{X, Y_k, 1 \leq k \leq n\}$  的情况, 称

$$E(X|Y_1, \dots, Y_n) \triangleq \sum_{j_1} \cdots \sum_{j_n} I_{(Y_k=j_k, 1 \leq k \leq n)}(\omega) \times \\ E(X|Y_1 = j_1, Y_2 = j_2, \dots, Y_n = j_n)$$

为  $X$  关于  $(Y_1, \dots, Y_n)$  的条件数学期望. 类似可定义一般多元随机变量作为条件的条件数学期望.

若  $E|X|, E|X_i| < \infty, 1 \leq i \leq 2, E|g(Y_1, \dots, Y_n)| < \infty$ , 则类似有:

- ①  $E(\alpha_1 X_1 + \alpha_2 X_2 | Y_1, \dots, Y_n) = \sum_{i=1}^2 \alpha_i E(X_i | Y_1, \dots, Y_n) \quad \text{a.s.};$
- ②  $E[g(Y_1, \dots, Y_n)X | Y_1, \dots, Y_n] = g(Y_1, \dots, Y_n)E(X | Y_1, \dots, Y_n) \quad \text{a.s.};$
- ③ 如  $X$  与  $Y_1, \dots, Y_n$  独立, 则  $E(X | Y_1, \dots, Y_n) = EX \quad \text{a.s.}$
- ④  $EX = E[E(X | Y_1, \dots, Y_n)] \quad \text{a.s.}$
- ⑤  $\forall 1 \leq m < n$

$$E(X | Y_1, \dots, Y_m) = E[E(X | Y_1, \dots, Y_n) | Y_1, \dots, Y_m] \\ = E[E(X | Y_1, \dots, Y_m) | Y_1, \dots, Y_n] \quad \text{a.s.}$$

证明从略.

## 7. 条件乘法公式与条件独立性

(1) 条件概率的乘法公式

设  $A, B$  为两个随机事件, 由条件概率的定义可知  $P(AB) = P(A)P(B|A)$ .

与上面的概率乘法公式类似, 条件概率的乘法公式如下:

**命题 1.4.1** 设  $A, B, C$  为 3 个随机事件, 则

$$P(BC|A) = P(B|A)P(C|AB). \quad (1.4.14)$$

**证明** 按条件概率的定义, 当  $P(AB) > 0$  时

$$P(BC|A) = \frac{P(ABC)}{P(A)} = \frac{P(AB)}{P(A)} \frac{P(ABC)}{P(AB)} = P(B|A)P(C|AB).$$

因此按对条件概率的等式的有关约定(1.4.14) 式成立.  $\square$

(2) 条件独立性

当两个随机事件  $A, B$  独立时, 有  $P(AB) = P(A)P(B)$ , 即  $P(A|B) = P(A)$ . 同样, 与上面的独立性概念类似, 条件独立性的定义如下:

**定义 1.4.5** 设  $A, B, C$  为 3 个随机事件, 称事件  $A, C$  关于事件  $B$  **条件独立**, 若满足

$$P(C|AB) = P(C|B). \quad (1.4.15)$$

对于条件独立性有如下结论:

**命题 1.4.2** 设  $A, B, C$  为 3 个随机事件, 则事件  $A, C$  关于事件  $B$  条件独立的充要条件为

$$P(AC|B) = P(A|B)P(C|B). \quad (1.4.16)$$

**证明** 必要性. 由命题 1.4.1, 则

$$P(AC|B) = P(A|B)P(C|AB).$$

当  $P(AB) = 0$  时,  $P(A|B) = 0$ , 因此 (1.4.16) 式两边均为 0, 而当  $P(AB) > 0$  时, 将 (1.4.15) 式代入上式即得 (1.4.16) 式.

充分性. 只需考虑  $P(AB) > 0$  的情形, 由命题 1.4.1 及 (1.4.16) 式可得

$$P(C|AB) = \frac{P(AC|B)}{P(A|B)} = P(C|B). \quad \square$$

本书有关初等概率论的内容, 读者可参考文献 [22].

## 1.5 随机过程的概念

在概率论中, 研究了随机变量,  $n$  维随机向量. 在极限定理中, 涉及到了无穷多个随机变量, 但局限在它们之间是相互独立的情形. 将上述情形加以推广, 即研究一族无穷多个、相互有关的随机变量, 这就是随机过程.

### 1. 概念

设对每一个参数  $t \in T$ ,  $X(t, \omega)$  是一随机变量, 称随机变量族  $X_T = \{X(t, \omega), t \in T\}$  为一**随机过程**(stochastic process) 或称随机函数. 其中  $T \subset \mathbb{R}$  是一实数集, 称为指标集.

用映射来表示  $X_T$ ,

$$X(t, \omega): T \times \Omega \rightarrow \mathbb{R},$$

即  $X(\cdot, \cdot)$  是定义在  $T \times \Omega$  上的二元单值函数, 固定  $t \in T$ ,  $X(t, \cdot)$  是定义在样本空间  $\Omega$  上的函数, 即为一随机变量. 对于  $\omega \in \Omega$ ,  $X(\cdot, \omega)$  ( $t$  在  $T$  中顺序变化) 是参数  $t \in T$  的一般函数, 通常称  $X(\cdot, \omega)$  为样本函数, 或称随机过程的一个实现, 或说是一条轨道. 记号  $X(t, \omega)$  有时也写为  $X_t(\omega)$  或简记为  $X(t)$  或  $X_t$ .

参数  $t \in T$  一般表示时间或空间. 参数集  $T$  常用的有 3 种: (1)  $T_1 = \mathbb{N}_0 = \{0, 1, 2, \dots\}$ , (2)  $T_2 = \mathbb{Z} = \{\dots, -2, -1, 0, 1, 2, \dots\}$ , (3)  $T_3 = [a, b]$ , 其中  $a$  可以取  $-\infty$  或  $0$ ,  $b$  可以取  $+\infty$ . 当  $T$  取可列集 ( $T_1$  或  $T_2$ ) 时, 通常称  $X_T$  为随机序列.

$X_T$  的取值也可以是复数,  $\mathbb{R}^n$  或更一般的抽象空间.  $X_t (t \in T)$  可能取值的全体所构成的集合称为**状态空间**, 记作  $S$ .  $S$  中的元素称为状态.



## 2. 例子

(1) 质点在直线上的随机游动. 设一质点在时刻  $t = 0$  时处于位置  $a$  (整数), 以后每隔单位时间, 分别以概率  $p$  及  $q = 1 - p$  向正的或负的方向随机移动一个单位, 记  $X_n$  为质点在时刻  $t = n$  的位置. 固定  $n$ ,  $X_n$  是随机变量. 考虑不同的  $n$  时,  $\{X_n, n \geq 0\}$  是一随机序列.

(2) 考虑某“服务站”在  $[0, t]$  内来的“顾客”数, 记为  $N(t)$ , 固定  $t$ ,  $N(t)$  就是一随机变量. 因此  $\{N(t), t \geq 0\}$  是一随机过程. 这里的“顾客”可以是电话的“呼唤”, 通信设备中的“信号”, 一个系统的“更换设备”, 放散性物质衰变的“粒子”等.

(3) 在外界是随机载荷条件下, 某零件  $t$  时的应力  $X(t)$  是随机的, 故  $\{X(t), t \in T\}$  是一随机过程.  $X(t)$  亦可表示某电路中的电压、设备的温度、河流的流量 (或水位), 以及气体的压力等等.

(4) 考虑某输入输出系统, 例如最简单的 R-C 电路, 设输入端有一个干扰信号电压, 记为  $\xi(t)$ , 记  $Q(t)$  为  $t$  时电路的电量, 则它满足

$$R \frac{dQ(t)}{dt} + \frac{1}{C} Q(t) = \xi(t).$$

由于  $\{\xi(t), t \in T\}$  是一随机过程, 容易理解  $\{Q(t), t \in T\}$  也是一随机过程, 上式是一个最简单的随机微分方程.

## 3. 随机过程的数字特征及有限维分布函数族

设  $\{X(t), t \in T\}$  是一随机过程. 为了刻画它的概率特征, 通常用到随机过程的均值函数、方差函数、协方差函数 (相关函数) 以及有限维分布函数族及特征函数族等概念.

(1) 均值函数. 随机过程  $\{X(t), t \in T\}$  的**均值函数**定义为 (以下均假定右端存在)

$$m(t) \triangleq E(X(t)).$$

(2) 方差函数. 随机过程  $\{X(t), t \in T\}$  的**方差函数**定义为

$$D(t) \triangleq E\{(X(t) - m(t))^2\}.$$

(3) 协方差函数. 随机过程  $\{X(t), t \in T\}$  的**协方差函数**定义为

$$R(s, t) \triangleq \text{cov}(X(s), X(t)).$$

(4) 相关函数. 随机过程  $\{X(t), t \in T\}$  的**相关函数**定义为

$$\rho(s, t) \triangleq \frac{\text{cov}(X(s), X(t))}{\sqrt{D(s)D(t)}}.$$

(5) 有限维分布族. 设  $t_i \in T, 1 \leq i \leq n$  ( $n$  为任意正整数), 记

$$\begin{aligned} & F(t_1, t_2, \dots, t_n; x_1, x_2, \dots, x_n) \\ &= P(X(t_1) \leq x_1, X(t_2) \leq x_2, \dots, X(t_n) \leq x_n), \end{aligned}$$

其全体

$$\{F(t_1, t_2, \dots, t_n, x_1, x_2, \dots, x_n), t_1, t_2, \dots, t_n \in T, n \geq 1\}$$

称为随机过程的**有限维分布族**. 它具有以下两个性质:

① 对称性 对  $(1, 2, \dots, n)$  的任一排列  $(j_1, j_2, \dots, j_n)$ , 有

$$F(t_{j_1}, t_{j_2}, \dots, t_{j_n}; x_{j_1}, x_{j_2}, \dots, x_{j_n}) = F(t_1, t_2, \dots, t_n; x_1, x_2, \dots, x_n).$$

② 相容性 对  $m < n$ , 有

$$\begin{aligned} & F(t_1, \dots, t_m, t_{m+1}, \dots, t_n; x_1, \dots, x_m, \infty, \dots, \infty) \\ &= F(t_1, \dots, t_m; x_1, \dots, x_m). \end{aligned}$$

一个随机过程的概率特性完全由其有限维分布族决定.

(6) 特征函数. 记

$$\begin{aligned}\phi(t_1, t_2, \dots, t_n; \theta_1, \dots, \theta_n) &= E\{\exp\{i[\theta_1 X(t_1) + \dots + \theta_n X(t_n)]\}\} \\ &= \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} \exp\{i[\theta_1 x_1 + \dots + \theta_n x_n]\} \times \\ &\quad F(t_1, \dots, t_n; dx_1, \dots, dx_n),\end{aligned}$$

称  $\{\phi(t_1, \dots, t_n; \theta_1, \dots, \theta_n), n \geq 1, t_1, \dots, t_n \in T\}$  为随机过程  $\{X(t), t \in T\}$  的有限维特征函数族.

## 1.6 随机过程的分类

设  $X_T = \{X(t), t \in T\}$  为随机过程, 按其概率特征, 分类如下.

### 1. 独立增量过程

对  $t_1 < t_2 < \dots < t_n, t_i \in T, 1 \leq i \leq n$ , 若增量

$$X(t_1), X(t_2) - X(t_1), X(t_3) - X(t_2), \dots, X(t_n) - X(t_{n-1})$$

相互独立, 则称  $\{X(t), t \in T\}$  为**独立增量过程**(process with independent increments). 若对一切  $0 \leq s < t$ , 增量  $X(t) - X(s)$  的分布只依赖于  $t - s$ , 则称  $X_T$  有平稳增量. 有平稳增量的独立增量过程简称为独立平稳增量过程.

常见的泊松 (Poisson) 过程和维纳 (Wiener) 过程 (或称布朗运动 (Brownian motion)) 就是两个最简单也是最重要的独立平稳增量过程.

### 2. 马尔可夫过程

粗略地说, 一随机过程, 若已知现在的  $t$  状态  $X_t$ , 那么将来状态  $X_u (u > t)$  取值 (或取某些状态) 的概率与过去状态  $X_s (s < t)$  取值无关, 或更简单地, 已知现在, 将来与过去无关 (条件独立), 则称此性

质为马尔可夫性 (无后效性或简称为马氏性). 具有这种马尔可夫性的过程称为马尔可夫过程. 精确定义为:

随机过程  $\{X_t, t \in T\}$ , 若对任意  $t_1 < t_2 \cdots < t_n < t, x_i, 1 \leq i \leq n$ , 及  $A \subset \mathbb{R}$ , 总有

$$P(X_t \in A | X_{t_1} = x_1, X_{t_2} = x_2, \cdots, X_{t_n} = x_n) = P(X_t \in A | X_{t_n} = x_n),$$

则称此过程为**马尔可夫过程**(Markov process), 简称马氏过程.

称  $P(s, x; t, A) = P(X_t \in A | X_s = x)(s < t)$  为转移概率函数 (transition probability function).

$X_t$  的取值全体构成的集合记为  $S$ , 称为状态空间. 对于马尔可夫过程  $X_T = \{X_t, t \in T\}$ , 当  $S = \{1, 2, 3, \cdots\}$  为可列无限集或有限集时, 通常称为**马尔可夫链**(Markov chain), 简称马氏链.

样本函数是连续的马尔可夫过程  $\{X_t, t \in [0, \infty]\}$  称为扩散 (diffusion) 过程. 泊松过程是一个最简单连续时间马尔可夫链, 而布朗运动则是一个最简单的扩散过程.

### 3. 平稳过程及二阶矩过程

(1) 宽平稳过程 (或协方差平稳过程)

一随机过程  $X_T$ , 若对  $\forall \tau, t \in T, D(X(t))$  存在且

$$E(X(t)) = m, \text{cov}(X_t, X_{t+\tau}) = R(\tau)$$

仅依赖  $\tau$ , 则称  $X_T$  为**宽平稳过程**(wide sense stationary process), 即它的协方差不随时间推移而改变.

(2) 二阶矩过程

一随机过程  $X_T$ , 若对  $\forall t \in T, DX_t$  存在, 则称为**二阶矩过程** (finite second moments process).

(3) 严平稳过程

一随机过程  $X_T$ , 若对  $\forall t_1, t_2, \dots, t_n \in T$ , 及  $h > 0$ ,  $(X_{t_1}, X_{t_2}, \dots, X_{t_n})$  与  $(X_{t_1+h}, X_{t_2+h}, \dots, X_{t_n+h})$  有相同的联合分布, 则称该过程为**严平稳过程**(strictly stationary process). 严平稳过程的一切有限维分布对时间的推移保持不变. 特别地  $X(t), X(s)$  的二维分布只依赖于  $t - s$ .

尽管从实际应用的角度来看, 要求追溯到无穷的未来似乎有点不现实, 但为数学讨论方便, 平稳过程 (包括宽、严两种情况) 的指标集应取为  $(-\infty, +\infty)$  或全体整数 (离散时间情形).

#### 4. 鞅

若对  $\forall t \in T, E|X(t)| < \infty$ , 且对  $\forall t_1 < t_2 < \dots < t_n < t_{n+1}$ , 有

$$E(X(t_{n+1})|X(t_1), X(t_2), \dots, X(t_n)) = X(t_n) \quad \text{a.s.},$$

则称  $\{X(t), t \in T\}$  为**鞅**(martingales).

近十多年, 鞅在现代科技中有越来越广泛的应用.

#### 5. 更新过程

设  $(X_k, k \geq 1)$  为独立同分布的正的随机变量序列, 对  $\forall t > 0$ , 令  $S_0 = 0, S_n = \sum_{k=1}^n X_k$ , 并定义

$$N(t) = \max\{n: n \geq 0, S_n \leq t\},$$

称  $\{N(t), t \geq 0\}$  为**更新过程**(renewal process).

$N(t)$  可以解释为  $[0, t]$  内更换零件的个数或系统来的信号 (粒子) 数, 或 “服务站” 来的 “顾客数” 等.

#### 6. 点过程 (或称计数过程)

一个随机过程  $\{N(A), A \subset T\}$  是一**点过程**(point process), 若  $N(A)$  表示在集合  $A$  中 “事件” 发生的总数, 即它满足:

- (1) 对  $\forall A \subset T, N(A)$  是一取值非负整数的随机变量 ( $N(\emptyset) = 0$ );
- (2) 对  $\forall A_1, A_2 \subset T$ , 若  $A_1 A_2 = \emptyset$ , 则对每一个样本有  $N(A_1 \cup A_2) = N(A_1) + N(A_2)$ .

**注** 参数集  $T$  可以是  $\mathbb{R}^n$ , 也可以是任意一抽象非空集.  
泊松过程是简单的点过程.